INSTITUTO DE
TECNOLOGIA E
LIDERANÇA - INTELI

24 de Novembro de 2025

Quantization Strategies for Low-Resource Hardware in Deep Learning Applications

Orientador

Rodrigo Mangoni Nicola

Alunos

Caio Martins de Abreu

Filipi Enzo Siqueira Kikuchi

Pablo Ruan Lana Viana

Introdução

As **CNNs** são essenciais na visão computacional, porém exigem muita **memória** e **processamento**. Em sistemas embarcados, essas redes em precisão total tornam-se difíceis de executar em tempo real.

Objetivos

Este trabalho avalia técnicas de quantização pós-treinamento (**PTQ**) em **CNNs**, examinando impacto em **latência**, **CPU**, **memória** e desempenho no hardware embarcado, demonstrando a viabilidade e importância da otimização para IA eficiente.

Hipótese

Modelos quantizados mantêm desempenho próximo ao **FP32**, enquanto reduzem drasticamente o custo computacional, tornando-se mais adequados para dispositivos embarcados.

Quantização Estática

A quantização estática usa **calibração** para converter **pesos** e **ativações** em **INT8**, reduzindo memória e latência, preservando estabilidade e acurácia em hardware embarcado.

Quantização Dinâmica

A quantização dinâmica **converte pesos** para **INT8** em **tempo de execução,** ajustando ativações dinamicamente, agilizando inferência sem calibração e mantendo desempenho eficiente em dispositivos de baixo recurso.

Modelo Selecionado

YOLOv8n foi escolhido por combinar alta acurácia, baixa latência e eficiência computacional. Sua arquitetura **anchor-free** e modular facilita o treino e a aplicação de **PTQ**, tornando-o ideal para hardware embarcado limitado.

Conjunto de Dados

O conjunto de dados contem **3.737** imagens variadas, anotadas manualmente e padronizadas no **Roboflow** para 640×640. Dividido em treino/validação/teste, inclui múltiplas pessoas por cena e resolução média de **0,92 MP**.

Hardware

O **Raspberry Pi 5** foi utilizado como plataforma de testes de baixo recurso para avaliar os efeitos da **PTQ** em modelos **YOLO**, medindo latência de inferência, uso de memória e acurácia, fornecendo um ambiente realista para implantação de IA embarcada.

Resultados

Quantização reduz **latência**, melhora **throughput** e diminui **memória**, com pequeno impacto na acurácia. A **quantização estática** oferece maior aceleração enquanto a **dinâmica** mantém melhor fidelidade, preservando distribuição de confiança e desempenho consistente

Análise de Latência

A quantização estática **reduziu** significativamente a **latência** e **aumentou** o **throughput**, embora com maior uso de **CPU**. A dinâmica ofereceu ganhos moderados e maior **adaptabilidade**, mantendo **eficiência** e consumo de **memória** estáveis.

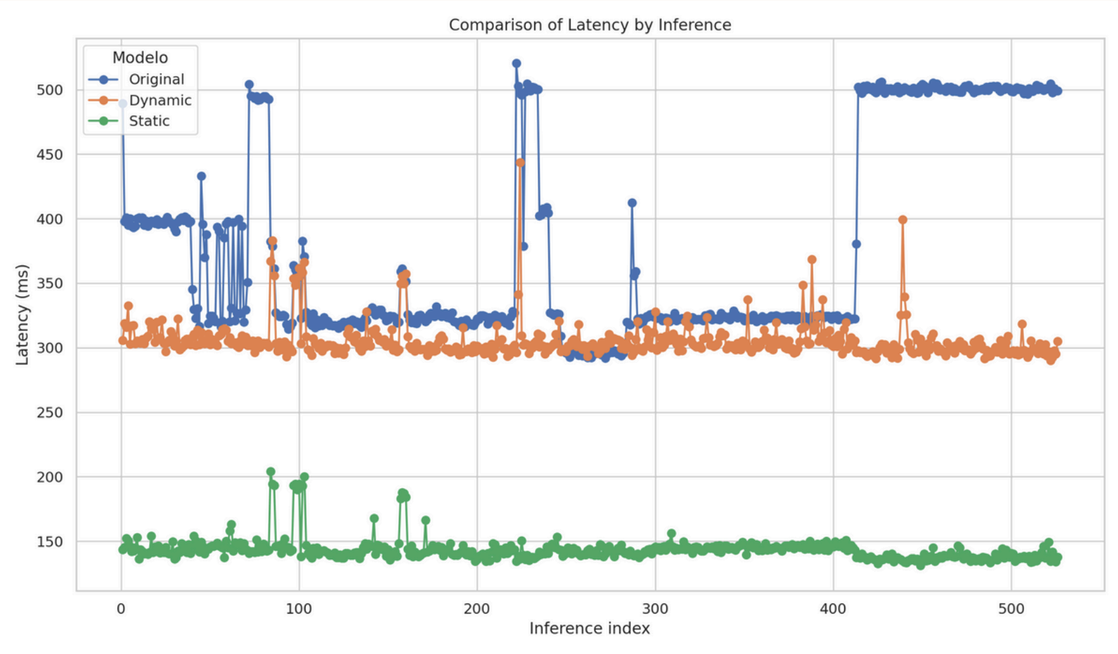

Análise de Memória

A quantização estática **reduziu** cerca de **9%** da memória e mostrou uso mais estável. A dinâmica trouxe leve redução, mas **maior flexibilidade**. Ambas melhoram a eficiência em sistemas embarcados.

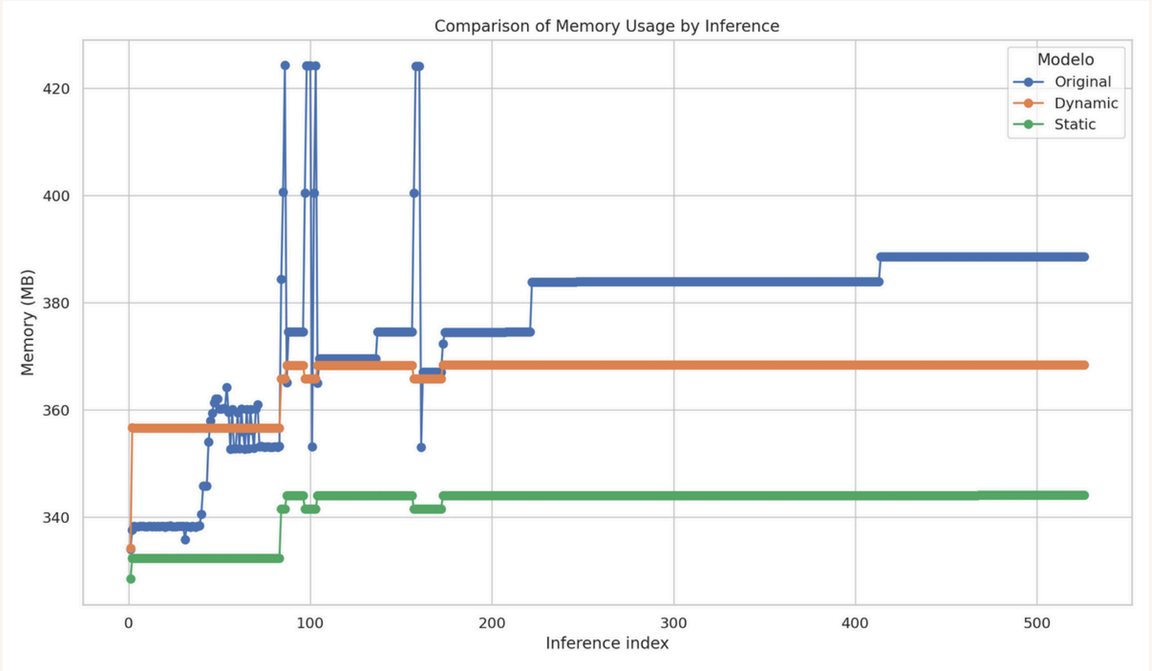

Análise de Acurácia

A análise mostra que a quantização **dinâmica** mantém o comportamento do modelo **original**, enquanto a estática reduz levemente as **confidências**. Mesmo assim, ambas preservam a **confiabilidade** geral, equilibrando eficiência computacional e fidelidade preditiva

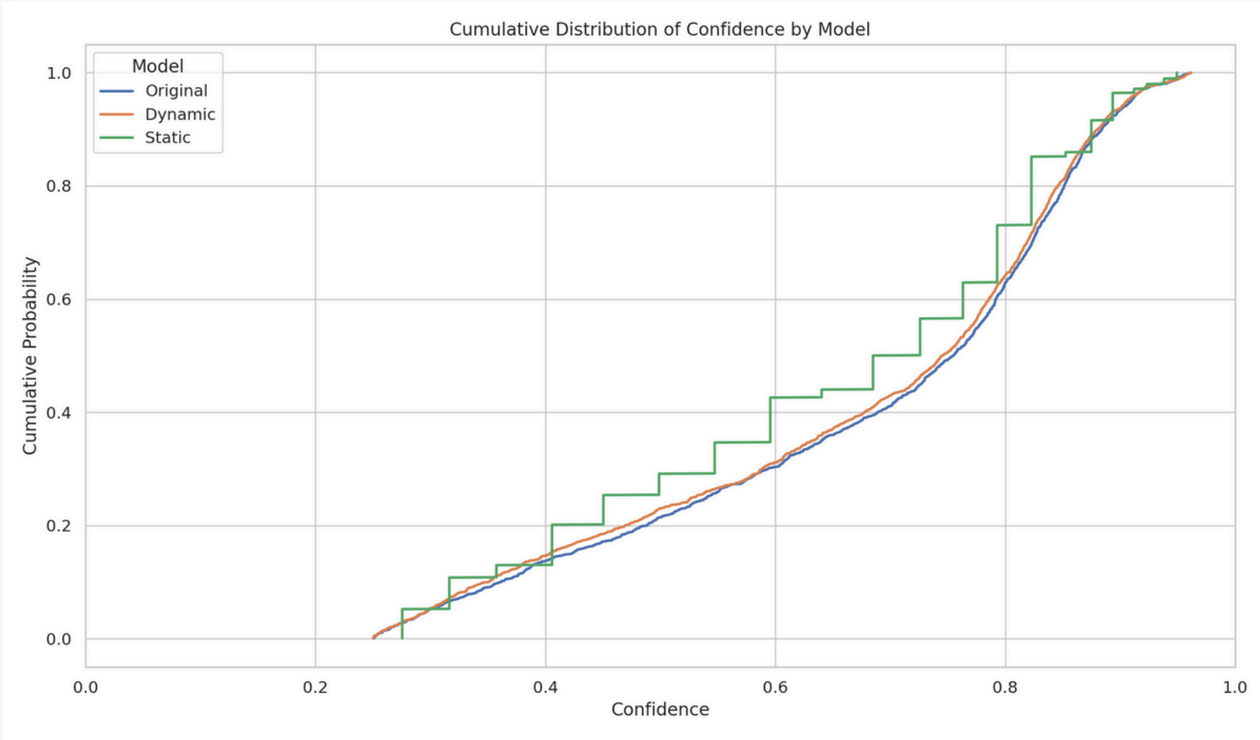

Conclusão

A quantização demonstra-se eficaz para implementar deep learning em hardware limitado. A quantização estática oferece maior desempenho e baixa latência, enquanto a dinâmica traz flexibilidade. Ambas equilibram **acurácia**, **eficiência** e **velocidade**, viabilizando visão computacional em dispositivos de borda.